

Game Classification – LLM Zero-Shot Project

Integrantes

Claudio Dias Alves – RA: 10403569

Daniel Rubio Camargo – RA: 10408823

João Pedro Mascaro Baccelli – RA: 10224004

Introdução

Este projeto faz parte do End-to-End AI Open Project e segue a Opção 1 – Text Classification (foco em LLMs). O objetivo é classificar descrições de jogos em gêneros como Action, Adventure, RPG, Shooter, Strategy, Puzzle e Horror utilizando Modelos de Linguagem (LLMs) modernos. Usamos Zero-Shot Classification, permitindo que o modelo determine o gênero mais provável mesmo sem treinamento específico no dataset.

Referencial

O avanço da Inteligência Artificial possibilitou o uso de grandes modelos de linguagem (LLMs) capazes de compreender contexto, semântica e relações lógicas entre sentenças. A abordagem Zero-Shot utilizada neste projeto se apoia em tarefas de Natural Language Inference (NLI), permitindo que o modelo avalie a compatibilidade entre a descrição de um jogo e cada gênero possível. Isso é fruto da evolução dos modelos de Deep Learning e arquiteturas Transformer, alinhado aos conteúdos estudados ao longo da disciplina, como IA Clássica vs. ML, Redes Neurais, MLP, Deep Learning e Transfer Learning.

Métodos

1. Preparação e Coleta de Dados

Embora o modelo não exija treinamento supervisionado, realizamos um levantamento de dados reais através da RAWG API para testar descrições diversas. Essa etapa envolve:

- Requisições HTTP
- Pré-processamento simples
- Organização tabular
- Validação de campos

Este processo faz referência direta ao conteúdo de coleta e preparação de dados estudado nas aulas de Aprendizado Supervisionado e Regressão.

2. Classificação Zero-Shot com LLM (HuggingFace Transformers)

Aplicamos o pipeline oficial de Zero-Shot Classification utilizando o HuggingFace Transformers:

- Modelo utilizado: valhalla/distilbart-mnli-12-1
- Entrada: descrição em inglês do jogo
- Saída: pontuação de entailment para cada gênero

Internamente, o modelo utiliza tarefas de Natural Language Inference (NLI), vinculadas a conceitos como:

- Representações distribuídas
- Redes neurais profundas
- Funções de ativação
- Propagação direta em transformadores

Esse método está diretamente associado aos conteúdos vistos nas semanas 6–10 da disciplina, incluindo Modelos Neurais, Perceptron, MLP, Deep Learning, TensorFlow e Transfer Learning.

3. Interface em Streamlit (Explainable AI)

Para atender aos requisitos de UX definidos no projeto, desenvolvemos uma interface interativa utilizando Streamlit. Os principais elementos incluem:

- Campo de entrada para descrição do jogo
- Exibição das probabilidades previstas para cada classe
- Barra de confiança real-time
- Explicação textual do funcionamento do modelo

Essa abordagem segue práticas de explicabilidade e transparência discutidas no módulo de IA Generativa – Riscos e Transparência.

Conclusão

O sistema final classifica o gênero de um jogo apenas por sua descrição textual, demonstrando a eficiência de modelos Zero-Shot e o potencial dos LLMs para soluções de classificação sem treinamento supervisionado. A combinação de coleta de dados, processamento inteligente e interface explicável compõe um projeto completo e alinhado aos objetivos da disciplina.

Referências

VanderPlas, J. (2016). *Python Data Science Handbook*. O'Reilly Media.

Disponível em: <https://jakevdp.github.io/PythonDataScienceHandbook/>

IA Generativa: Fundamentos, Usos e Riscos. (2023). Capítulos 8–10, páginas 151–172.

Russell, S., & Norvig, P. (2010). *Artificial Intelligence: A Modern Approach*. Prentice Hall.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

Williams, A., Nangia, N., & Bowman, S. R. (2018). *A Broad-Coverage Challenge for Sentence Understanding (MNLI)*. NAACL.

RAWG. (2024). *RAWG Video Game API Documentation*. Disponível em:

<https://rawg.io/apidocs>. Acesso em: 17 nov. 2025.

Streamlit Inc. (2024). *Streamlit Documentation*. Disponível em: <https://docs.streamlit.io/>. Acesso em: 17 nov. 2025.